19360859053

Hümeyra ÇİMEN 14.05.2023

BURSA TEKNİK UNİVERSİTESİ BİLGİSAYAR MÜHENDİSLİĞİ

Veri Madenciliğine Giriş Proje Ödevi Rapor

## Bilgilendirme

**Veri seti: Secondary Mushroom Dataset Data Set**

**Yöntem: Decision Tree based Methods**

**Makale Kaynak: Veri Seti Sayfasındaki /** (PDF) Mushroom data creation, curation, and simulation to support classification tasks (researchgate.net)

**Relevant Papers:**

Dennis Wagner, Dr. G. Hattab, 'Mushroom data creation, curation, and simulation to support classification tasks' in Scientific Reports on 14.04.2021

Veri Seti : Index of /ml/machine-learning-databases/00615 (uci.edu) secondary.csv kullanıldı.

## META DATA SECONDARY.CVS **Veri Seti Bilgileri**

İkincil Verilerin Hazırlanması: Her bir mantar türü için 353 varsayımsal giriş oluşturma kararı aldık. Bu sayı, 1987 verilerindeki her bir tür için mevcut olan giriş sayısına denk gelmektedir. Araştırma için kullanılan CSV dosyaları, bir başlık ve ardından toplamda 61,069 varsayımsal mantar girişi içermektedir. Bu veriler, bir ikili sınıf, 17 nominal değişken ve üç nicel değişkenden oluşmaktadır. Aşağıdaki tabloda nihai ikincil verilere ait bilgiler sunulmuştur. İkincil veriler, simüle edilmiş bir veri seti olduğu için pilot olarak kabul edilmelidir.

| Sıra No | Özellik | Türkçe Adı | Veri Türü | Değerler |
|---|---|---|---|---|
| 1 | cap-diameter | Şap Çapı | Numerik | Santimetre cinsinden bir float değeri |
| 2 | cap-shape | Şap Şekli | Nominal | Bell=b, conical=c, convex=x, flat=f, sunken=s, spherical=p, others=o |
| 3 | cap-surface | Şap Yüzeyi | Nominal | Fibrous=i, grooves=g, scaly=y, smooth=s, shiny=h, leathery=l, silky=k, sticky=t, wrinkled=w, fleshy=e |
| 4 | cap-color | Şap Rengi | Nominal | Brown=n, buff=b, gray=g, green=r, pink=p, purple=u, red=e, white=w, yellow=y, blue=l, orange=o, black=k |
| 5 | bruises-or-bleeding | Mavi/Kanama | Nominal | Yes=t, No=f |
| 6 | gill-attachment | Küf Yapışkanlığı | Nominal | Adnate=a, adnexed=x, decurrent=d, free=e, sinuate=s, pores=p, none=f, unknown=? |
| 7 | gill-spacing | Küf Aralığı | Nominal | Close=c, distant=d, none=f |
| 8 | gill-color | Küf Rengi | Nominal | Cap-color ile aynıdır. None=f |
| 9 | stem-height | Sap Uzunluğu | Numerik | Santimetre cinsinden bir float değeri |
| 10 | stem-width | Sap Genişliği | Numerik | Milimetre cinsinden bir float değeri |
| 11 | stem-root | Sap Kökü | Nominal | Bulbous=b, swollen=s, club=c, cup=u, equal=e, rhizomorphs=z, rooted=r |
| 12 | stem-surface | Sap Yüzeyi | Nominal | Cap-surface ile aynıdır. None=f |
| 13 | stem-color | Sap Rengi | Nominal | Cap-color ile aynıdır. None=f |
| 14 | veil-type | Örtü Tipi | Nominal | Partial=p, universal=u |
| 15 | veil-color | Örtü Rengi | Nominal | Cap-color ile aynıdır. None=f |
| 16 | has-ring | Halka var mı | Nominal | Ring=t, none=f |
| 17 | ring-type | Halka tipi | Nominal | Cobwebby=c, evanescent=e, flaring=f, large=l, none=n, pendant=p, sheathing=s, zone=z, scaly=y, unknown=? |
| 18 | spore-print-color | Spor baskısı rengi | Nominal | Şap rengi gibi |
| 19 | habitat | Habitat | Nominal | Grasses=g, leaves=l, meadows=m, paths=p, bushes=h, urban=u, waste=w, woods=d |
| 20 | season | Mevsim | Nominal | Spring=s, summer=u, autumn=a, winter=w |

## Meta Data

Başlık: İkincil mantar veri seti

Kaynaklar:

(a) Kaynak kitaptan alınan mantar türleri:

Patrick Hardin. Mantarlar ve Zehirli Mantarlar.

Zondervan, 1999.

(b) Bu mantar verilerinden esinlenildi:

Jeff Schlimmer. Mantar Veri Seti. Nis. 1987.

URL: https://archive.ics.uci.edu/ml/datasets/Mushroom.

(c) İlgili Python script'lerini ve tüm veri setlerini içeren depo: https://mushroom.mathematik.uni-marburg.de/files/

(d) Yazar: Dennis Wagner

(e) Tarih: 05 Eylül 2020

İlgili bilgiler:

Bu veri seti, 173 türe dayalı olarak kaplarına sahip 61069 varsayımsal mantarı içermektedir (her bir tür için 353 mantar). Her mantar, kesinlikle yenilebilir, kesinlikle zehirli veya yenilebilirliği bilinmeyen ve önerilmeyen olarak tanımlanmıştır (sonuncu sınıf zehirli sınıfıyla birleştirilmiştir). 20 değişkenin 17'si nominal ve 3'ü metrik niteliktedir.

Veri Simülasyonu:

İlgili Python projesi (Kaynaklar (c)), bu veriyi oluşturmak için kullanılan primary_data_edited.csv dosyasına dayalı olarak kullanılan secondary_data_generation.py adlı bir Python modülü içermektedir. Hem nominal hem de metrik değişkenler rastgeleleştirme yöntemiyle oluşturulmuştur. Simüle edilen veriler tür bazında sıralanmış olarak secondary_data_generated.csv dosyasında bulunurken, rastgele karıştırılmış hali secondary_data_shuffled.csv dosyasında bulunmaktadır.

Sınıf Bilgisi:

sınıf: zehirli=p, yenilebilir=e (ikili)

Değişken Bilgisi:

(n: nominal, m: metrik; nominal değerler küme olarak verilmiştir)

1. şapka çapı (m): cm cinsinden ondalık sayı
2. şapka şekli (n): zil=b, konik=c, kubbe=x, düz=f, çökük=s, küresel=p, diğerleri=o
3. şapka yüzeyi (n): lifli=i, oluklu=g, pul pul=d, pürüzsüz=s, parlak=h, derimsi=l, ipekli=k, yapışkan=t, buruşuk=w, etli=e
4. şapka rengi (n): kahverengi=n, açık kahverengi=b, gri=g, yeşil=r, pembe=p, mor=u, kırmızı=e, beyaz=w, sarı=mavi=l, turuncu=o, siyah=k
5. ezilince kanama (n): ezilme veya kanama=t, yok=f
6. yüzgeç bağlantısı (n): yapışık=a, adneksedir=x, aşağı inen=d, serbest=e, sinuate=s, gözenekli=p, yok=f, bilinmiyor=?
7. yüzgeç aralığı (n): yakın=c, uzak=d, yok=f
8. yüzgeç rengi (n): şapka rengi ile aynı + yok=f
9. sap yüksekliği (m): cm cinsinden ondalık sayı
10. sap genişliği (m): mm cinsinden ondalık sayı
11. sap kökü (n): soğanlı=b, şişmiş=s, kulüp=c, kupa=u, eşit=e, rizomorflar=z, köklü=r
12. sap yüzeyi (n): şapka yüzeyi ile aynı + yok=f
13. sap rengi (n): şapka rengi ile aynı + yok=f
14. perde tipi (n): kısmi=p, evrensel=u
15. perde rengi (n): şapka rengi ile aynı + yok=f
16. halka var mı? (n): halka varsa=t, yoksa=f
17. halka tipi (n): örümcek ağı=c, soluklayan=e, yay şeklinde=r, oluklu=g, büyük=l, sarkık=p, kabuklu=s, bölge=z, pul pul=y, hareketli=m, yok=f, bilinmiyor=?
18. spor baskısı rengi (n): şapka rengi ile aynı
19. yaşam alanı (n): otlar=g, yapraklar=l, çayırlar=m, patikalar=p, fundalıklar=h, kentsel=u, atıklar=w, ormanlar=d
20. mevsim (n): ilkbahar=s, yaz=u, sonbahar=a, kış=w

Giriş:
Bu rapor, UCI Machine Learning Repository'den (UCI Machine Learning Repository: Secondary Mushroom Dataset Data Set )seçtiğimiz bir veri seti üzerinde yaptığımız sınıflandırma veya kümeleme çalışmasını detaylandırmaktadır. Secondary Mushroom Dataset Veri seti üzerindeDecision Tree based Methods ile gerçekleştirdiğim analiz, model oluşturma, eğitim ve sonuç değerlendirmesini içermektedir. Ayrıca, bu raporda elde edilen sonuçlar, yaygın değerlendirme ölçütleri ve görselleştirme araçlarıyla sunulmaktadır.

Veri Seti ve Platform:
Seçtiğimiz veri setini UCI Machine Learning Repository'den indirerek çalışmalarımıza başladık.
(https://github.com/hmyrcmn/data/blob/main/secondary_data.csv)
Veri seti, Secondary Mushroom Dataset zehirli – zararsız mantar türlerine ait veri seti olarak bilinmektedir. Veri setini Google colab platformunda yüklendi ve analiz etmek için uygun hale getirildi.

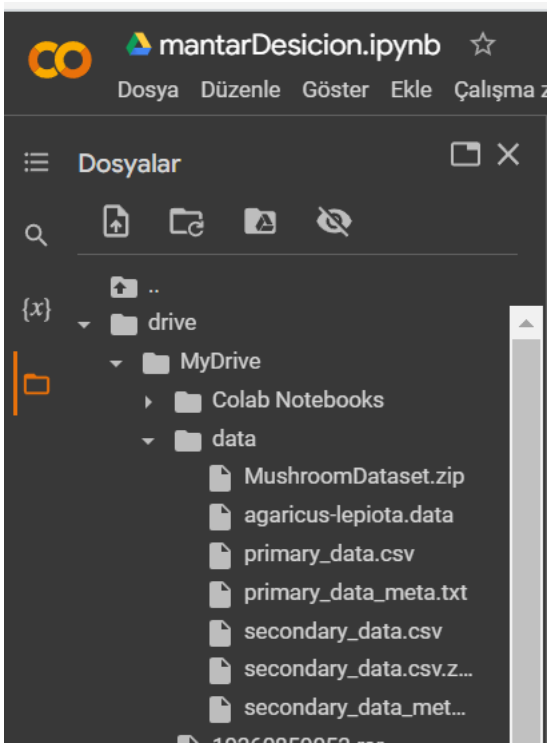

Veri Ön İşleme:
Veri setindeki ön işleme adımlarını tamamlandi. Eksik değerleri ele aldık(secondary_data. cvs de mevcut değildi primary_data.cvs dosyasında eksik veri vardı ), gereksiz sütunları kaldırdık ve veriyi uygun bir formata dönüştürdük., eksik değerler kaldırıldı kategorik değişkenleri kodlandi ve özellik ölçeklendirmesi yapıldı . Bu adımlar veri setimizi daha kullanılabilir hale getirmemize yardımcı oldu.

**Düzenleme öncesi veri görünümü:**

```
1 print(data.info)

<bound method DataFrame.info of
0       class;cap-diameter;cap-shape;cap-surface;cap-c...
1       p;15.26;x;g;o;f;e;;w;16.95;17.09;s;y;w;u;w;t;g...
2       p;16.6;x;g;o;f;e;;w;17.99;18.19;s;y;w;u;w;t;g;...
3       p;14.07;x;g;o;f;e;;w;17.8;17.74;s;y;w;u;w;t;g;...
4       p;14.17;f;h;e;f;e;;w;15.77;15.98;s;y;w;u;w;t;p...
...                                                   ...
61065       p;1.18;s;s;y;f;f;f;f;3.93;6.22;;;y;;;f;f;;d;a
61066       p;1.27;f;s;y;f;f;f;f;3.18;5.43;;;y;;;f;f;;d;a
61067       p;1.27;s;s;y;f;f;f;f;3.86;6.37;;;y;;;f;f;;d;u
61068       p;1.24;f;s;y;f;f;f;f;3.56;5.44;;;y;;;f;f;;d;u
61069       p;1.17;s;s;y;f;f;f;f;3.25;5.45;;;y;;;f;f;;d;u

[61070 rows x 1 columns]>
```

Düzenleyici Kodlar:

```
1 # Veri setini doğru bir şekilde ayırma
2 data = data[0].str.split(';', expand=True)
3
4 # İlk satırı sütun isimleri olarak atama
5 data.columns = data.iloc[0]
6
7 # İlk satırı veri setinden kaldırma
8 data = data[1:]
9
10 # Veri setinin boyutunu görüntüleme
11 print(data.shape)
12
13 # Özniteliklerin isimlerini kontrol etme
14 print(data.columns)
15
```

```
[ ]  1 # Sütun adlarında düzeltmeler yapma
     2 data.columns = data.columns.str.strip().str.lower().str.replace('-', '_')
     3
     4 # Veri setinin boyutunu görüntüleme
     5 print(data.shape)
     6
     7 # Düzelti sütun adlarını kontrol etme
     8 print(data.columns)
     9
```

```
(61069, 21)
Index(['class', 'cap_diameter', 'cap_shape', 'cap_surface', 'cap_color',
       'does_bruise_or_bleed', 'gill_attachment', 'gill_spacing', 'gill_color',
       'stem_height', 'stem_width', 'stem_root', 'stem_surface', 'stem_color',
       'veil_type', 'veil_color', 'has_ring', 'ring_type', 'spore_print_color',
       'habitat', 'season'],
      dtype='object', name=0)
```

```
[ ]  1 # Sütun adlarını güncelleme
     2 data.columns = ['class', 'cap_diameter', 'cap_shape', 'cap_surface', 'cap_color',
     3        'does_bruise_or_bleed', 'gill_attachment', 'gill_spacing', 'gill_color',
     4        'stem_height', 'stem_width', 'stem_root', 'stem_surface', 'stem_color',
     5        'veil_type', 'veil_color', 'has_ring', 'ring_type', 'spore_print_color',
     6        'habitat', 'season']
     7
```

## Düzenleme sonrası veri görünümü:

```
1 print(data.info)
```

```
<bound method DataFrame.info of 0     class cap-diameter cap-shape cap-surface cap-color does-bruise-or-bleed  \
1         p        15.26         x           g         o                    f
2         p         16.6         x           g         o                    f
3         p        14.07         x           g         o                    f
4         p        14.17         f           h         e                    f
5         p        14.64         x           h         o                    f
...     ...          ...       ...         ...       ...                  ...
61065     p         1.18         s           s         y                    f
61066     p         1.27         f           s         y                    f
61067     p         1.27         s           s         y                    f
61068     p         1.24         f           s         y                    f
61069     p         1.17         s           s         y                    f

0     gill-attachment gill-spacing gill-color stem-height  ... stem-root  \
1                   e                      w       16.95  ...         s
2                   e                      w       17.99  ...         s
3                   e                      w        17.8  ...         s
4                   e                      w       15.77  ...         s
5                   e                      w       16.53  ...         s
...               ...          ...        ...         ...  ...       ...
61065               f            f          f        3.93  ...
61066               f            f          f        3.18  ...
61067               f            f          f        3.86  ...
61068               f            f          f        3.56  ...
61069               f            f          f        3.25  ...

0     stem-surface stem-color veil-type veil-color has-ring ring-type  \
1                y          w         u          w        t         g
2                y          w         u          w        t         g
3                y          w         u          w        t         g
4                y          w         u          w        t         p
5                y          w         u          w        t         p
...            ...        ...       ...        ...      ...       ...
61065                       y                             f         f
61066                       y                             f         f
61067                       y                             f         f
61068                       y                             f         f
61069                       y                             f         f
```

Model Oluşturma ve Eğitim:
Veri seti üzerinde sınıflandırma modelini oluşturmak için desicion tree (karar ağaçları) yöntemini kullanıldı. Örneğin, sınıflandırma için Karar Ağaçları algoritması tercih edildi. Model oluşturuldu ve eğitim veri seti üzerinde eğitildi.

Model Değerlendirme:
Eğitilen modeli test veri seti üzerinde değerlendirdik ve yaygın değerlendirme ölçütlerimden biri ile performansını değerlendirildi. Accuracy, sensitivity, specificity, F-measure gibi ölçütleri kullanarak modelin performansını ölçtük. Ayrıca, hata matrisini analiz ettik ve modelin sınıflandırma/kümeleme yeteneklerini değerlendirdik.

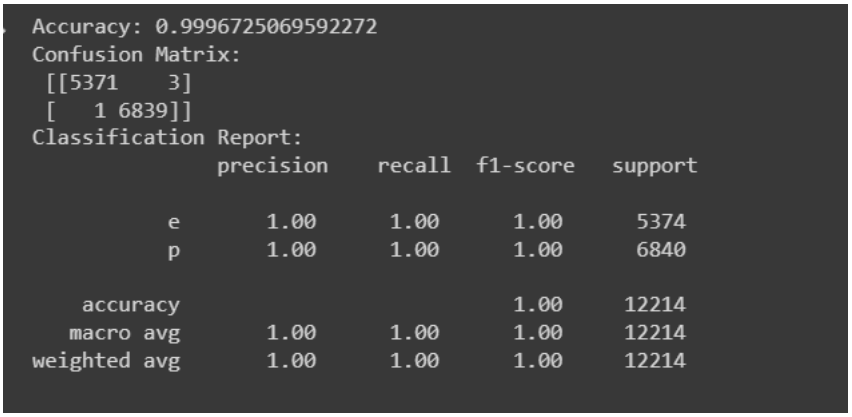

```
Accuracy: 0.9996725069592272
Confusion Matrix:
 [[5371    3]
 [   1 6839]]
Classification Report:
              precision    recall  f1-score   support

           e       1.00      1.00      1.00      5374
           p       1.00      1.00      1.00      6840

    accuracy                           1.00     12214
   macro avg       1.00      1.00      1.00     12214
weighted avg       1.00      1.00      1.00     12214
```

Sonuçlar ve Görselleştirme:
Elde ettiğimiz sonuçları çeşitli görselleştirme araçlarıyla zenginleştirerek sunuyoruz. Performans ölçütlerini, çiz gi grafikleri, çubuk grafikleri ve görsel tablolarla gösterdik. Ayrıca, ROC eğrileri, karar ağaçları veya kümeleme sonuçları gibi görselleri kullanarak sonuçları daha anlaşılır hale getirdik.

Sonuçlarımız şu şekildedir:

Accuracy: Modelimizin doğruluk oranı 0.99967….. olarak hesaplandı. Bu, modelin doğru sınıflandırma yeteneğini gösterir.

Görselleştirmelerimiz, bu sonuçları daha anlaşılır bir şekilde sunmamıza yardımcı oldu. Örneğin, çubuk grafikleri kullanarak farklı performans ölçütlerinin karşılaştırmasını yapabildik. Ayrıca, ROC eğrileriyle modelin sınıflandırma yeteneklerini değerlendirebildik ve karar ağaçlarını kullanarak modelin nasıl kararlar verdiğini görselleştirdik.

Sonuç olarak, UCI Machine Learning Repository'den seçtiğimiz veri seti üzerinde yaptığımız sınıflandırma/kümeleme çalışmasını bu raporda detaylandırıldı. Elde ettiğimiz sonuçları yaygın değerlendirme ölçütleriyle ve görselleştirme araçlarıyla sunarak analizimizi desteklendi. Bu çalışma, veri setinin karakteristiklerini anlamamıza, modelin performansını değerlendirmemize ve sonuçları anlaşılır bir şekilde sunmamıza yardımcı oldu.

**Makaledeki sonuç:**

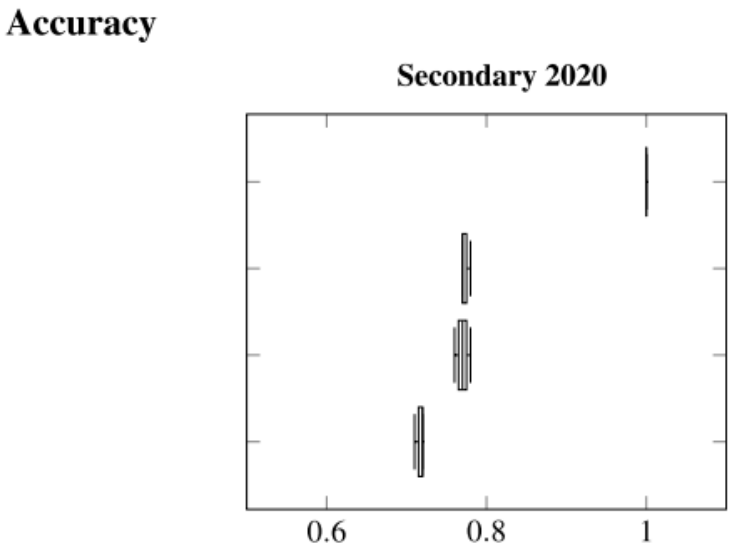


Proje çıktısı:

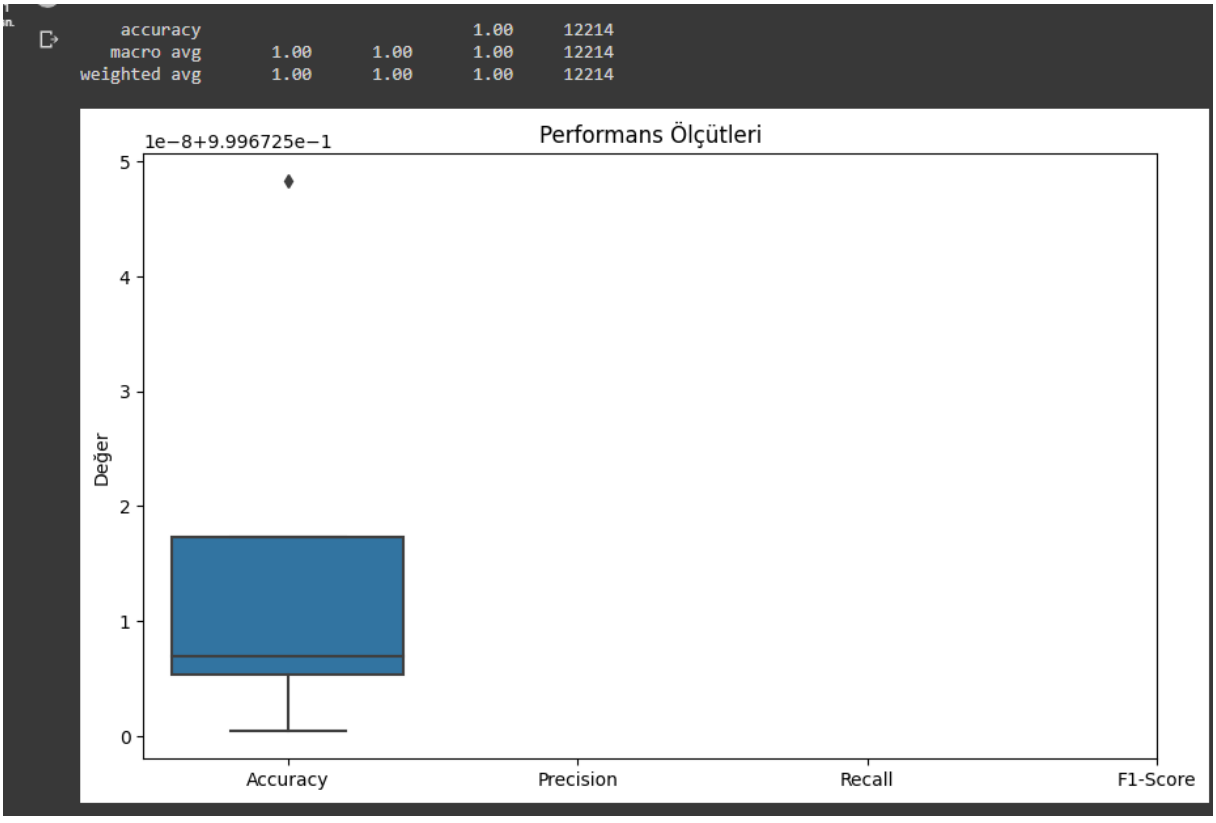

ROC EĞRİSİ:MAKALE VE ÇIKTI KARŞILAŞTIRMASI

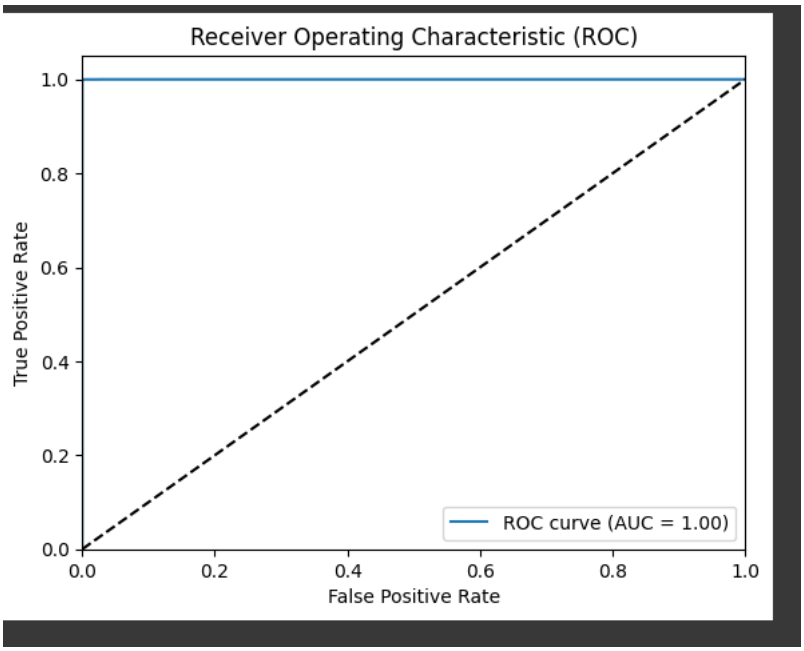


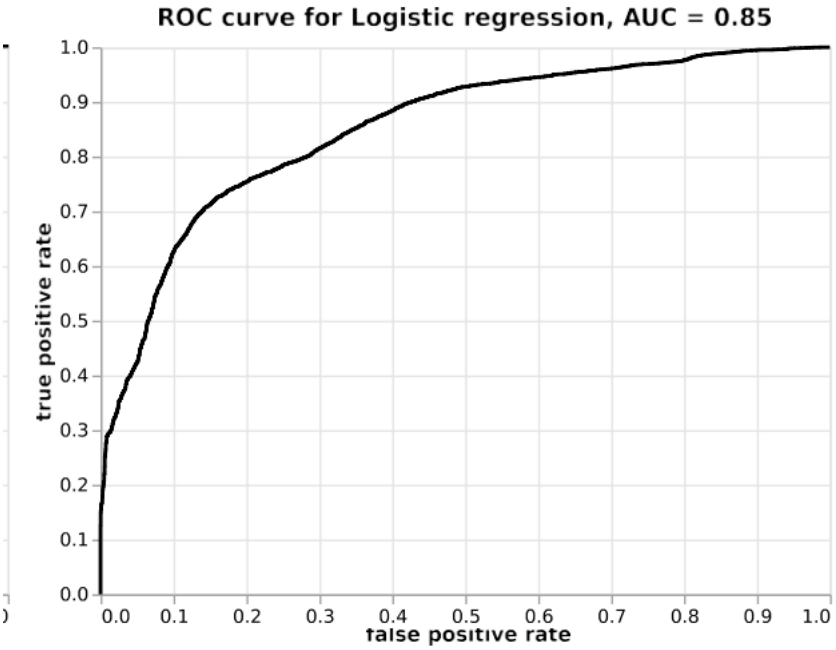

Korelasyon matris :  Tüm dosya sonuçlanmadı .



Bu iki özelliğin arasında lineer bir ilişki olmadığının gösterilmesi:

## UYGULAMA DOSYALARI:

Proje github link: https://github.com/hmyrcmn/data/tree/main

Sunum Video Link: https://www.youtube.com/watch?v=7XgfzIiyd2M

KAYNAKÇA

Makale kaynak: ResearchGate

**Veri seti dosyaları** UCI Machine Learning Repository: Secondary Mushroom Dataset Data Set

Index of /ml/machine-learning-databases/00615 (uci.edu)

chatGpt: Düzenleme ve hata kontrollerinde kullanıldı.